

[Análise e caracterização de episódios de Freezing of Gait (FOG) em indivíduos com Parkinson utilizando dispositivos vestíveis]

Projeto e Análise de Experimentos

[Graziele de Cássia Rodrigues]





UFOP



**DEPARTAMENTO DE
COMPUTAÇÃO E SISTEMAS**

Objetivos

Desenvolver um modelo preditivo para detectar episódios de congelamento da marcha em pacientes com Parkinson, com base em dados de aceleração de um sensor lombar.



Aceleração de um sensor lombar em três eixos:
Z - vertical
ML – médio lateral
AP - anteroposterior

Experimento Fatorial 2k

Comparar o desempenho do algoritmo Light GBM em diferentes condições.

Tamanho da Janela	Tamanho da Base	Engenharia de Features	Descrição
100	0.5	4 Momentos Distribuição	Curtose, Assimetria, Média, Variância
100	0.5	Medidas Descritivas	Mínimo, Máximo, Média, Amplitude
100	1	4 Momentos Distribuição	Curtose, Assimetria, Média, Variância
100	1	Medidas Descritivas	Mínimo, Máximo, Média, Amplitude
200	0.5	4 Momentos Distribuição	Curtose, Assimetria, Média, Variância
200	0.5	Medidas Descritivas	Mínimo, Máximo, Média, Amplitude
200	1	4 Momentos Distribuição	Curtose, Assimetria, Média, Variância
200	1	Medidas Descritivas	Mínimo, Máximo, Média, Amplitude


desempenho (Acurácia, Precisão, Recall e F1-Score) foram coletadas para cada repetição, resultando em um total de 80 execuções ($2^3 * 10 = 80$).

Accuracy

Fator	Efeito	Variação	Intervalo Confiança
window_size	0.0055	19.63%	[0.0009, 0.0055, 0.010]
sample_frac	0.0088	50.52%	[0.0042, 0.0088, 0.013]
calc_type	-0.0057	21.38%	[-0.0103, -0.0057, -0.0012]
window_size sample_frac	0.0002	0.037%	[-0.0043, 0.0002, 0.0048]
window_size calc_type	-0.0030	5.71%	[-0.0075, -0.0030, 0.0016]
sample_frac calc_type	0.0001	0.0004%	[-0.0045, 0.0000, 0.0046]
window_size sample_frac_calc_type	-0.0003	0.0586%	[-0.0048, -0.0003, 0.0042]
Erro		2.63%	

Métrica	Valor
SST	0.0122
SSE	0.00032
MSE	4.5e^-5
DESVIO	0.0067

Gráfico de Interação: sample_frac e calc_type




Precision

Fator	Efeito	Variação	Intervalo Confiança
window_size	0.0110	46.67%	[0.0049, 0.0110, 0.0172]
sample_frac	0.0105	42.52%	[0.0044, 0.0105, 0.0167]
calc_type	-0.0020	1.52%	[-0.0081, -0.0020, 0.0042]
window_size sample_frac	-0.0003	0.03%	[-0.0064, -0.0003, 0.0059]
window_size calc_type	-0.0039	5.78%	[-0.0100, -0.0039, 0.0023]
sample_frac calc_type	-0.0007	0.16%	[-0.0068, -0.0007, 0.0055]
window_size sample_frac_calc_type	-0.0011	0.49%	[-0.0073, -0.0011, 0.0050]
Erro		2.83%	

Métrica	Valor
SST	0.0208
SSE	0.00059
MSE	8.4e ⁻⁵
DESVIO	0.0091

Gráfico de Interação: window_size e sample_frac

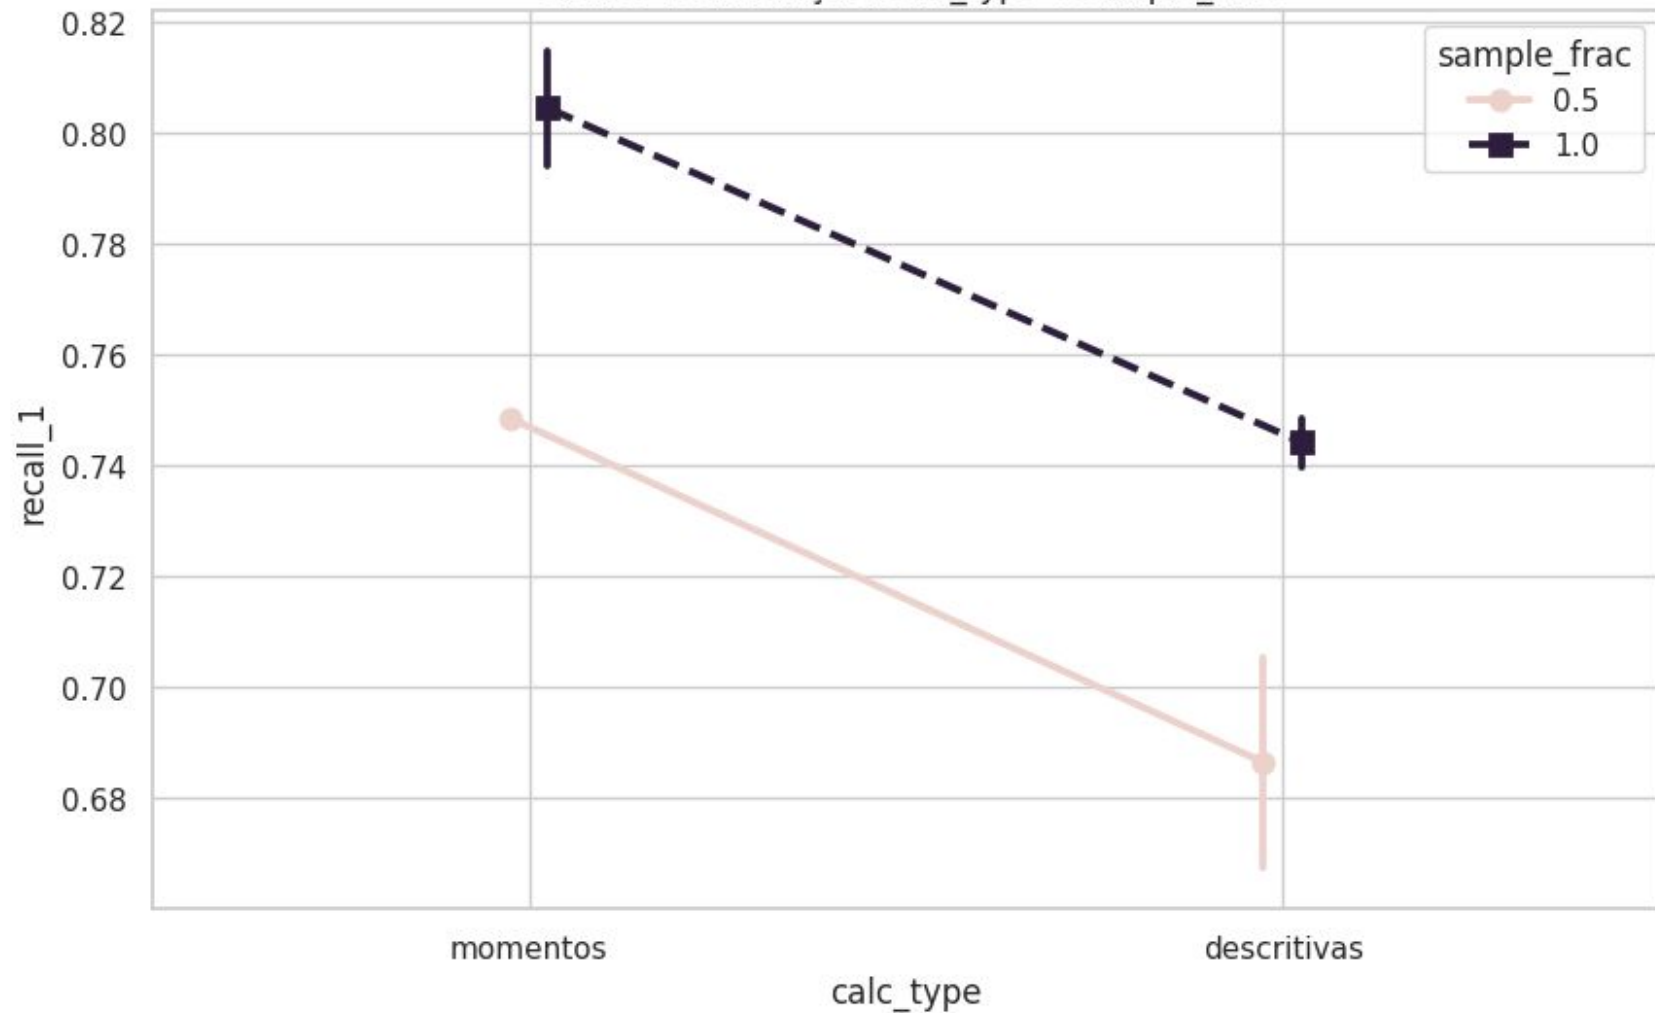


Recall

Fator	Efeito	Variação	Intervalo Confiança
window_size	0.0031	0.52%	[-0.0127, 0.0031, 0.0188]
sample_frac	0.0262	38.48%	[0.0104, 0.0262, 0.0420]
calc_type	-0.0313	54.81%	[-0.0471, -0.0313, -0.0155]
window_size sample_frac	0.0020	0.23%	[-0.0137, 0.0020, 0.0178]
window_size calc_type	-0.0067	5.71%	[-0.0225, -0.0067, 0.0090]
sample_frac calc_type	0.0032	2.54%	[-0.0126, 0.0032, 0.0190]
window_size sample_frac_calc_type	0.0014	0.11%	[-0.0144, 0.0014, 0.0172]
Erro		2.72%	

Métrica	Valor
SST	0.1431
SSE	0.00389
MSE	0.00055
DESVIO	0.0235

Gráfico de Interação: calc_type e sample_frac




F1

Fator	Efeito	Variação	Intervalo Confiança
window_size	0.0073	8.01%	[-0.0027, 0.0073, 0.0173]
sample_frac	0.0179	47.98%	[0.0079, 0.0179, 0.0279]
calc_type	-0.0155	36.23%	[-0.0103, -0.0057, -0.0012]
window_size sample_frac	0.0009	0.13%	[-0.0091, 0.0009, 0.0110]
window_size calc_type	-0.0054	4.39%	[-0.0154, -0.0054, 0.0046]
sample_frac calc_type	0.0014	0.31%	[-0.0086, 0.0014, 0.0115]
window_size sample_frac_calc_type	0.0001	0.0001%	[-0.0099, 0.0001, 0.0101]
Erro		2.94%	

Métrica	Valor
SST	0.05327
SSE	0.00156
MSE	0.00022
DESVIO	0.01495

Gráfico de Interação: sample_frac e calc_type



Melhor configuração:

- window_size = 200
- sample_frac = 1 (100%)
- eng features: momentos (curtose, assimetria, média, variância)

```
def run_model():  
    # Carregar e processar os dados de treino  
    train_data = load_and_preprocess_data('/content/drive/MyDrive/UFOP/trabalhoAnalise/train', sample_frac=1)  
    train_data = add_rolling_window_features(train_data, 200)  
  
    # Seleção de Features e Labels  
    features = ['Time', 'AccV', 'AccML', 'AccAP',  
                'AccV_rolling_kurtosis', 'AccV_rolling_skewness', 'AccV_rolling_var', 'AccV_rolling_mean',  
                'AccML_rolling_kurtosis', 'AccML_rolling_skewness', 'AccML_rolling_var', 'AccML_rolling_mean',  
                'AccAP_rolling_kurtosis', 'AccAP_rolling_skewness', 'AccAP_rolling_var', 'AccAP_rolling_mean']  
  
    train_features = train_data[features]  
    train_labels = train_data['IsFOG']  
  
    # Definindo e treinando o modelo  
    model = LGBMClassifier(  
        n_estimators=100,  
        num_leaves=30,  
        max_depth=10,  
        learning_rate=0.1,  
        is_unbalance=True,  
        objective='binary'  
    )  
    model.fit(train_features, train_labels)
```

Resultados

- Accuracy: 85.65%
- Precision: 71.68%
- Recall: 81.46%
- F1-Score: 76.26%

Resultados

Time	AccV	AccML	AccAP	AccV_r	AccV_r	AccV_r	AccV_r	AccML	AccML	AccML	AccML	AccAP	AccAP	AccAP	AccAP	IsFOG_pre(x)
3	-9,690020418	0,811827262	-2,256483721	-3,41	0,458	0,023	-9,87	1,672	-1,35	8E-04	0,811	0,943	-0,77	0,003	-2,25	0
4	-9,679606925	0,875915705	-2,343682331	-3,03	-0,23	0,025	-9,83	1,077	-0,04	0,001	0,824	-2,15	-0,1	0,004	-2,27	0
5	-9,729980056	0,98727168	-2,577943777	-2,02	-0,63	0,022	-9,82	2,421	1,401	0,006	0,851	2,818	-1,58	0,019	-2,32	0
6	-9,866056818	0,92354858	-2,725240291	-1,7	-0,42	0,018	-9,82	0,017	0,773	0,005	0,862	0,029	-1,13	0,039	-2,38	0
7	-10,0775927	0,94029847	-2,692860462	-1,75	-0,24	0,024	-9,86	-1,05	0,326	0,005	0,872	-1,67	-0,59	0,046	-2,42	0
8	-10,2471475	0,952427774	-2,418180849	-0,66	-0,53	0,038	-9,9	-1,43	0,01	0,005	0,881	-1,28	-0,61	0,04	-2,42	0
9	-10,20983476	0,914102582	-2,202798408	-1,34	-0,27	0,043	-9,93	-1,22	-0,15	0,005	0,884	-1,02	-0,75	0,04	-2,4	0
10	-9,988553895	0,967632732	-2,063741694	-1,14	-0,18	0,039	-9,94	-1,26	-0,33	0,005	0,891	-0,72	-0,6	0,046	-2,37	0
11	-9,609236612	0,78165158	-1,755734358	-1,14	-0,2	0,045	-9,91	-1,53	-0,15	0,006	0,882	0,551	0,298	0,073	-2,32	0
12	-9,530970409	0,884202737	-1,484380944	-1,07	-0,15	0,052	-9,88	-1,32	-0,16	0,005	0,882	0,922	0,822	0,12	-2,25	0
13	-9,493890563	0,730765326	-1,489069758	-1,09	-0,15	0,058	-9,85	-1,11	-0,24	0,006	0,872	-0,11	0,701	0,153	-2,2	0
14	-9,558983862	0,791845598	-1,452587065	-1,14	-0,27	0,06	-9,83	-1,25	-0,07	0,006	0,866	-0,74	0,55	0,179	-2,15	0
15	-9,627641577	1,040968887	-1,555858586	-1,08	-0,39	0,059	-9,82	-0,91	0,109	0,008	0,877	-1,13	0,369	0,189	-2,11	0

Resultados

Time	AccV	AccML	AccAP	AccV_r	AccV_r	AccV_r	AccV_r	AccML	AccML	AccML	AccML	AccAP	AccAP	AccAP	AccAP	IsFOG_pre(%)
1220	-9,683936216	0,11727229	1,332493071	2,148	-0,7	0,373	-9,66	2,637	-0,1	0,457	0,232	3,551	-0,82	0,627	1,669	1
1221	-9,709168205	0,223651342	1,326727386	2,179	-0,7	0,371	-9,66	2,656	-0,1	0,456	0,234	3,65	-0,82	0,619	1,661	1
1222	-9,733949432	0,330383354	1,320183901	2,236	-0,7	0,368	-9,67	2,661	-0,11	0,456	0,235	3,767	-0,84	0,609	1,652	1
1223	-9,771599745	0,381924583	1,344703989	2,314	-0,71	0,363	-9,67	2,659	-0,11	0,456	0,236	3,898	-0,86	0,599	1,643	1
1224	-9,825809936	0,462545704	1,454555299	2,405	-0,72	0,357	-9,68	2,657	-0,11	0,456	0,236	4,043	-0,89	0,588	1,635	1
1225	-9,793058709	0,559446287	1,54250906	2,512	-0,76	0,349	-9,69	2,657	-0,11	0,456	0,236	4,183	-0,91	0,579	1,628	1
1289	-10,24179369	0,390178624	1,427288662	11,66	-0,57	0,113	-9,7	11,86	-0,83	0,139	0,257	9,343	1,949	0,193	1,533	1
1290	-10,23645011	0,354791251	1,719338646	5,724	0,996	0,091	-9,69	11,02	-2,01	0,118	0,247	10,24	1,936	0,18	1,526	1
1291	-10,11388586	0,299574659	2,002423357	5,661	1,352	0,085	-9,69	11,65	-2,74	0,107	0,24	10,73	1,958	0,176	1,524	1
1292	-9,861051578	0,261890702	2,206959843	5,65	1,358	0,085	-9,69	11,84	-2,77	0,106	0,238	10,51	1,942	0,177	1,525	1
1293	-9,524384764	0,280279301	2,303906422	6,063	1,36	0,082	-9,69	12,22	-2,82	0,105	0,24	10,05	1,896	0,18	1,529	1
1294	-9,192733988	0,309629498	2,283354658	6,264	1,309	0,079	-9,69	13,69	-2,92	0,098	0,247	9,723	1,859	0,182	1,535	1
1295	-8,851872344	0,334343489	2,175262678	6,021	1,338	0,082	-9,69	14,53	-2,82	0,084	0,255	9,776	1,894	0,18	1,543	1
1296	-8,503150091	0,317052291	1,910462203	5,841	1,439	0,088	-9,68	12,3	-2,3	0,067	0,265	10,25	2,064	0,174	1,55	1

A combinação de uma aceleração vertical negativa e uma anteroposterior positiva, juntamente com uma leve aceleração mediolateral, pode ser indicativa de uma fase de congelamento de marcha. Isso sugere que, embora a pessoa esteja tentando se mover para frente, ela enfrenta dificuldades, pois vertical predomina, resultando em uma dinâmica de marcha que pode ser característica do FOG.

Dúvidas?

Accuracy, Precision, Recall e F1 Score

Precisão: Quão confiável é o modelo quando faz uma previsão positiva?

Acurácia: Qual a proporção total de previsões corretas feitas pelo modelo?

Recall: Quão bom é o modelo em identificar todas as instâncias positivas?

F1 Score: Como o modelo equilibra precisão e recall?